1. Data Cleaning – Handling Missing Values

vérifier le nombre et le pourcentage de valeurs manquantes par variable, puis choisir une méthode de traitement selon les résultats:

Après l'application du masque spatial et la réduction de la résolution, une analyse des valeurs manquantes a été effectuée afin de déterminer si un traitement supplémentaire était nécessaire avant de passer aux étapes suivantes du preprocessing.

a) Identification des points géographiques valides

Le masque spatial permet d'identifier les cellules appartenant à la zone d'étude (Algérie). Après la réduction de résolution, le nombre de cellules géographiquement incluses dans le masque est de 5 430.

Cependant, l'analyse des données a montré que cinq de ces cellules ne contiennent aucune valeur exploitable pendant toute la période étudiée (140 mois). Ces cellules ont donc été exclues des points valides.

Le nombre réel de cellules exploitables est ainsi de :

[
5430-5=5425 \text{ cellules}
]

b) Vérification des valeurs manquantes

Afin de vérifier la présence éventuelle de valeurs manquantes, le dataset a été converti en DataFrame, puis les lignes contenant des valeurs manquantes ont été supprimées à l'aide de `dropna()`.

Sans suppression des valeurs manquantes :

Résultat : **1 339 520 lignes**, correspondant à : 92* 104 * 140 = 1,339,520

Après suppression des lignes contenant des valeurs manquantes :

Le nombre de lignes obtenu après cette opération est de **759 500**, ce qui correspond exactement au nombre de points valides multiplié par le nombre de mois :
5425 x 140 = 759,500
En effet, chaque point géographique valide est représenté par 140 observations temporelles, correspondant aux 140 mois de la période étudiée.

La vérification des valeurs manquantes restantes est effectuée donne : 0

1.3. Confirmation d'ERA5-Land

Selon la documentation officielle d'ECMWF, le produit ERA5-Land Monthly Averaged Reanalysis présente notamment deux problèmes connus qui doivent être pris en considération lors de son utilisation :

1. Valeurs incorrectes des variables accumulées (septembre 2022 – février 2024)

Une erreur a affecté les moyennes mensuelles de toutes les variables accumulées pendant cette période. La solution recommandée par ECMWF consiste à récupérer les valeurs correctes à partir du produit *Monthly averaged reanalysis by hour of day*, en utilisant l'échéance de 00:00.

Cette correction a été appliquée aux variables accumulées concernées dans notre dataset.

2. Permutation de trois variables liées à l'évaporation

Une erreur de permutation (*band-swap*) concerne les trois variables suivantes :

- Evaporation from bare soil ;
- Evaporation from open water surfaces excluding oceans ;
- Evaporation from vegetation transpiration.

Les valeurs de ces trois variables ont été échangées dans le produit mensuel. Ce problème concerne l'affectation des valeurs aux variables et non leur disponibilité.

Les 12 variables sélectionnées dans notre étude ne comprennent pas ces trois composantes individuelles de l'évaporation.

L'analyse réalisée sur notre dataset montre qu'après exclusion des lignes contenant des valeurs manquantes, nous obtenons exactement 759 500 observations, correspondant aux 5 425 points géographiques valides suivis pendant 140 mois.

Par conséquent, **aucune méthode d'imputation n'est nécessaire pour les données conservées**. Le dataset peut être utilisé directement pour les étapes suivantes du preprocessing.

1. Data Cleaning – Handling Outliers

L'analyse des distributions, à travers la skewness, la kurtosis et les boxplots, montre que certaines variables (`ro`, `tp`, `slhf` et `e`) présentent des distributions très asymétriques et des valeurs extrêmes. Cela nous conduit à examiner ces valeurs afin de distinguer les observations réellement anormales des variations climatiques naturelles.

Nous appliquerons donc, si nécessaire, des transformations adaptées, comme Log1p pour les variables positives (`ro`, `tp`) ou Yeo-Johnson pour les variables pouvant contenir des valeurs négatives (`slhf`, `e`). Les valeurs extrêmes physiquement plausibles seront conservées.

À partir des boxplots, nous avons observé que certaines variables présentent une distribution particulière, avec des valeurs éloignées du reste des observations.

L'analyse de la symétrie (skewness) et de l'aplatissement (kurtosis) a confirmé que quatre variables présentent un comportement statistique particulièrement marqué :

Variable	Skewness	Kurtosis	Comportement
`ro`	35.09	2439	Forte asymétrie à droite
`tp`	5.626	45.09	Forte asymétrie à droite
`slhf`	-3.977	19.23	Forte asymétrie à gauche
`e`	-3.978	19.24	Forte asymétrie à gauche

Cela ne signifie pas nécessairement que leurs valeurs sont erronées. Ces distributions peuvent aussi être liées à des phénomènes climatiques réels.

2. Data Cleaning – Discretization

La variable cible `t2m_next` étant initialement continue, nous devons la transformer en trois classes : Low, Medium et High. Nous appliquerons donc la méthode Equal-Width Binning afin de diviser son intervalle de valeurs en trois intervalles de même largeur.

3. Data Transformation – Scaling

L'examen des échelles des variables montre qu'elles présentent des ordres de grandeur très différents, allant de 10^{-9} (`ro`) à 10^{13} (`ssr`). Ces différences peuvent influencer les modèles sensibles à l'échelle des données, notamment les algorithmes basés sur les distances.

Nous appliquerons donc une mise à l'échelle avec StandardScaler ou RobustScaler, puis comparerons leurs effets sur les performances des modèles. StandardScaler sera également utilisé avant l'application de PCA.

4. Data Transformation – Aggregation

Notre dataset ERA5-Land contient déjà des observations organisées sous forme de moyennes mensuelles. Par conséquent, aucune agrégation mensuelle supplémentaire n'est nécessaire pour la partie supervisée.

5. Data Reduction – Low Variance Features

Pour examiner la variation relative des variables, nous utilisons le rapport entre l'écart-type et la médiane. Cette analyse montre que `sp` présente une faible dispersion relative (environ 3,5 %), ce qui indique une variation limitée par rapport à son ordre de grandeur.

Cette observation, associée à sa faible corrélation avec la cible (Spearman = 0,07), en fait une variable candidate à la suppression. Nous testerons son retrait et comparerons les performances des modèles avec et sans cette variable.

6. Data Reduction – Highly Correlated Features

L'analyse de Spearman et la clustermap révèlent de fortes corrélations entre certaines variables, notamment `slhf` et `e`, ainsi que `ro` et `tp`. Ces relations peuvent indiquer une redondance dans les informations fournies par ces variables.

Nous testerons donc différentes configurations en conservant ou en supprimant certaines variables fortement corrélées, afin d'évaluer leur impact sur les performances des modèles.

7. Data Reduction – Irrelevant Features

L'analyse de l'association entre le mois et la classe de température du mois suivant montre une relation importante, avec un Cramér's V de 0,69. Le mois apporte donc une information pertinente pour la prédiction de la température future.

Nous conserverons ainsi la variable `month` dans le dataset et pourrons également tester son encodage cyclique à l'aide de `month_sin` et `month_cos`.

8. Data Reduction – PCA

L'application de PCA après StandardScaler montre que les six premières composantes principales expliquent 90,27 % de la variance totale. Cela indique qu'il est possible de réduire les 12 variables initiales à six composantes tout en conservant une grande partie de l'information.

Nous testerons cette réduction principalement pour la partie non supervisée, puis comparerons les résultats obtenus avec et sans PCA.

9. Data Preprocessing – Class Distribution

L'analyse de la répartition des classes de la variable cible montre que Low représente 15,6 % des observations, Medium 43,8 % et High 40,6 %. Cette répartition révèle une représentation moins importante de la classe Low par rapport aux deux autres classes.

Nous vérifierons donc si ce déséquilibre affecte la capacité du modèle à prédire correctement chaque classe. Nous privilégierons notamment l'évaluation avec des métriques telles que le F1-score par classe et le Macro-F1. Un éventuel rééquilibrage des classes sera envisagé si les résultats le justifient.

Le probelme de la period 2022-2024:

Problème identifié et solution proposée

Lors de notre EDA, nous avons constaté une déformation du comportement temporel de sept variables ERA5-Land : `slhf`, `sshf`, `ssr`, `str`, `e`, `ro` et `tp`. Contrairement aux autres variables, elles ne suivent plus leur évolution cyclique habituelle pendant une partie de la période 2022–2024.

Après investigation, nous avons identifié une anomalie officiellement signalée par l'ECMWF, qui concerne les **variables accumulées** du produit *Monthly averaged reanalysis* entre **septembre 2022 et février 2024**.

Cette anomalie correspond à nos observations car les sept variables de notre dataset sont précisément des variables appartenant à la catégorie des **accumulations** dans la documentation ERA5-Land.

Variable	Signification	Type
`slhf`	Surface latent heat flux	Accumulée
`sshf`	Surface sensible heat flux	Accumulée
`ssr`	Surface net solar radiation	Accumulée
`str`	Surface net thermal radiation	Accumulée
`e`	Evaporation	Accumulée
`ro`	Runoff	Accumulée
`tp`	Total precipitation	Accumulée

En revanche, tes autres variables (`t2m`, `d2m`, `sp`, `u10`, `v10`) sont des variables instantanées. Elles ne sont donc pas concernées par cette anomalie particulière.

Solution : l'ECMWF recommande de récupérer les valeurs correctes à partir du produit *Monthly averaged reanalysis by hour of day*, en sélectionnant l'heure `00:00`. Il faudra ensuite remplacer les valeurs incorrectes des sept variables pour la période concernée, puis reconstruire notre dataset prétraité.

lien: Issue affecting ERA5-Land monthly averaged reanalysis for the period September 2022 to February 2024 - Announcements / C3S - Announcements - Forum
Solution:
Pour comprendre la correction appliquée aux variables accumulées, il est important de distinguer deux produits disponibles dans ERA5-Land :

1. Monthly averaged reanalysis

Ce produit contient les moyennes mensuelles des variables météorologiques. Il fournit une valeur représentative de chaque variable pour chaque mois.

Pour les variables instantanées, comme la température à 2 mètres (`t2m`) ou la pression (`sp`), il s'agit de moyennes mensuelles des valeurs horaires.

En revanche, les variables accumulées, comme les précipitations (`tp`) et les flux énergétiques (`ssr`, `str`, `slhf`, `sshf`), sont associées à des accumulations calculées sur des périodes de prévision. Leur traitement nécessite donc une attention particulière.

2. Monthly averaged reanalysis by hour of day

Contrairement au premier produit, celui-ci conserve une dimension supplémentaire : l'heure de la journée.

Pour chaque mois, il fournit des valeurs moyennes correspondant aux différentes heures de référence, de `00:00` à `23:00`.

Pour les variables accumulées, chaque heure correspond à une accumulation calculée depuis le début du forecast :

- `01:00` : accumulation correspondant à la première heure du forecast.
- `02:00` : accumulation depuis le début du forecast jusqu'à la deuxième heure.
- `03:00` : accumulation depuis le début du forecast jusqu'à la troisième heure.
- …
- `00:00` : accumulation sur les 24 heures précédentes (forecast step = 24 h).

Ces accumulations sont ensuite moyennées sur le mois pour chaque heure de référence.

3. Choix du produit pour la correction

Dans notre projet, nous avons utilisé le produit *Monthly averaged reanalysis by hour of day* pour corriger les sept variables accumulées affectées par le problème identifié dans les données ERA5-Land entre septembre 2022 et février 2024.

Nous avons sélectionné uniquement l'heure `00:00`, car elle correspond à l'accumulation sur les 24 heures précédentes, moyennée sur le mois. Elle permet ainsi de récupérer les valeurs mensuelles corrigées des variables accumulées.

Il est important de préciser que `00:00` correspond à une valeur de la coordonnée temporelle du jeu de données, et non à une colonne.

Cette sélection suit la méthode de récupération recommandée par l'ECMWF pour traiter les variables accumulées affectées par ce problème.

Les analyses qui déclenchent une action

#	Analyse de ton EDA	Ce qu'elle a montré	Action de preprocessing
1	**Univarié : asymétrie, 5 nombres, boxplots, quantile plot**	`tp`, `ro`, `slhf`, e ont de très grandes valeurs extrêmes (asymétrie jusqu'à 36)	Transformer en log (`tp`, `slhf`). Ne pas supprimer les extrêmes : ce sont de vrais épisodes de pluie
2	**Univarié : variance**	Les échelles vont de 10^{-9} (`ro`) à 10^{13} (`ssr`), échelles incompatible	`StandardScaler`, ajusté sur le train seulement
3	**Bivarié : corrélations et scatter entre variables**	`slhf`–`e` = 1.00, `ro`–`tp` = 0.98, `sshf`–`ssr` = −0.95	Supprimer e. Tester avec et sans `ro` et `sshf`
4	**Bivarié : chi-deux classe × mois** (V = 0.69)	Le mois détermine fortement la classe	Garder le mois et l'encoder en sin/cos
6	**Bivarié : répartition des classes**	Low 15.6 %, Medium 43.8 %, High 40.6 %	`class_weight="balanced"` et évaluation par F1 macro
7	**Multivarié : PCA (scree plot)**	6 composantes donnent 90 % de la variance	Une PCA en expérience, ajustée sur le train